Rafael Lindoso de Araujo, rla2@cesar.school
Rodrigo Borba, rsb7@cesar.school
Energy Consumption Dataset - Linear Regression → https://www.kaggle.com/datasets/govindaramsriram/energy-consumption-dataset-linear-regression

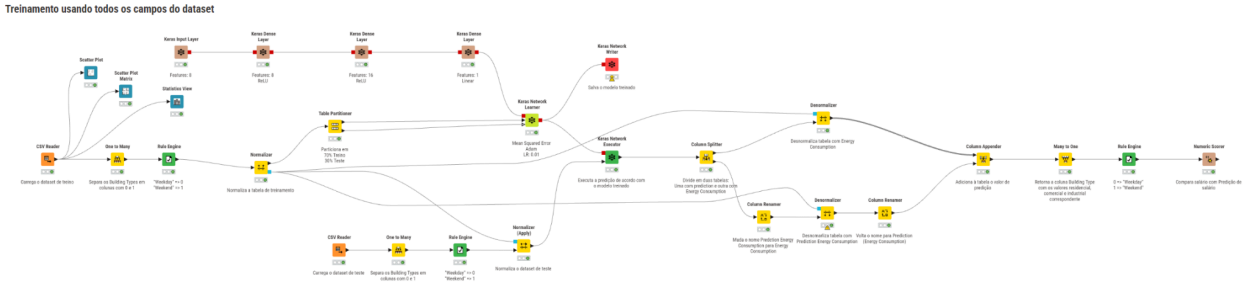

Abrir imagem

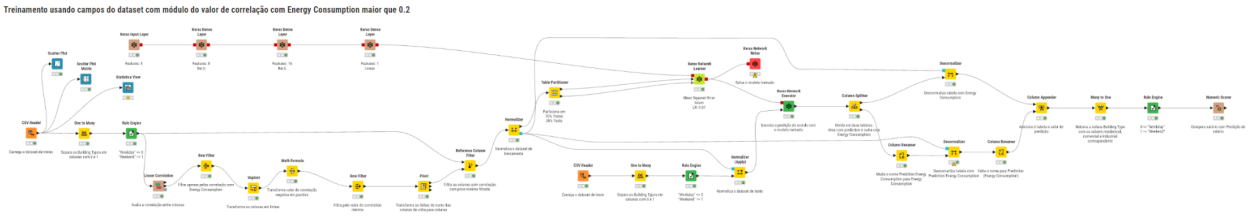

Abrir imagem

- Treinamento com todos os campos do dataset:

#	RowID	Prediction Number (Float)
1	R^2	0.999
2	mean absolute error	19.141
3	mean squared error	716.248
4	root mean squared error	26.763
5	mean signed difference	1.624
6	mean absolute percentage error	0.005
7	adjusted R^2	0.999

Os resultados utilizando todos os campos do dataset resultaram em um modelo con assertividade bem alto (R^2 = 0.999).
Para chegar nesse resultado, utilizamos três neurônios com 8 e 16 camadas ReLU e uma camada linear. Para o treinamento a função de perda utilizada foi o erro quadrático médio e o otimizador foi o Adam com Learning Rate (LR) 0.01.
A princípio, usamos o LR 0.001, que retornou um ótimo resultado (R^2 = 0.978). Mesmo assim, exploramos um pouco mais e chegamos no resultado melhor usando o LR 0.01.
Apesar do R^2 elevado, é importante observar se há diferença entre treino e validação, pois o uso de todas as variáveis pode aumentar o risco de overfitting.

- Treinamento com campos com correlação maior que 0.2:

#	RowID	Prediction Number (Float)
1	R^2	0.997
2	mean absolute error	35.415
3	mean squared error	2,351.693
4	root mean squared error	48.494
5	mean signed difference	3.328
6	mean absolute percentage error	0.009
7	adjusted R^2	0.997

Para chegar nesse resultado, utilizamos o nó Linear Correlation e eliminamos as colunas de temperatura média, dia da semana e comercial. Esta última retirada do campo tipo de construção.
As colunas removidas apresentaram baixa correlação com a variável alvo, indicando menor contribuição para o modelo.
O mesmo esquema de neurônios foi usado. Houve pequena redução (≈0,2%), considerada pouco relevante frente à simplificação do modelo. Como utilizamos menos

campos para treinar, o treino é um pouco mais rápido e a perda na performance é bem pequena.
Apesar da pequena queda no R^2, métricas como RMSE e MAE aumentaram, indicando maior erro absoluto nas previsões.
O modelo ficou mais simples e com menor custo computacional. Em datasets maiores, essa redução de dimensionalidade tende a trazer ganhos mais significativos em desempenho e generalização.

- Experiência e aprendizado:
  Uma das dificuldades encontradas durante o desenvolvimento foi a interpretação de valores negativos de correlação, que ainda não haviam sido observados por nós. Inicialmente, houve dúvida sobre seu significado, mas após pesquisa entendemos que a correlação negativa indica uma relação inversa entre as variáveis, ou seja, quando uma aumenta, a outra tende a diminuir.

  No momento de selecionar as variáveis com base no threshold definido, percebemos que era necessário considerar o valor absoluto da correlação, pois o que importa para o modelo é a intensidade da relação com a variável alvo, e não sua direção.